

FreeLLMAPI: Router Universal de Inteligencia Artificial

Manual Tecnico y Guia Operativa Oficial · Modo Experto ALEJAVI

Referencia: <https://youtu.be/7Oez8kmknOA> | Registro: 2026-09-20

1. DESGLOSE DE TIMESTAMPS Y CONCEPTOS OPERATIVOS:

- [00:00 - 05:12] Fragmentacion de APIs y unificacion en proxy unico OpenAI-compatible.
- [05:13 - 13:09] Catalogo de 34 plataformas y 605+ modelos con 7.4B tokens/mes.
- [13:10 - 14:40] Routing Strategy: Matriz de 295 reglas de prioridad y failover automatico.
- [14:41 - 20:34] AI Agent: Function calling, perfiles y soporte multimodal con MCPs.
- [20:35 - 23:38] Analysis & Logging: SQLite freeapi.db y exportacion a hbos_metricas.
- [23:39 - 25:08] Private Local Models: Emulacion de Ollama (:11434) y soberania de datos.
- [25:09 - 27:30] DeepSeek Harness: Aislamiento <think> y clamping termico 0.6-0.7.
- [27:31 - 28:26] Mobile App: PWA responsiva en LAN y tuneles cifrados.
- [28:27 - 29:15] Operacion Continua 24/7: Despliegue en VPS y compatibilidad UNBE.
- [29:16 - 32:45] Ajustes Avanzados: Cache, idempotency claims y cooldowns adaptativos.

2. ESPECIFICACION DEL HBOS-UNIFIED-GATEWAY (:3002):

- Puerto 3002: Desacoplado de FreeLLMAPI :3001 para cero conflicto de sockets.
- 239 Modelos Activos: 235 Zero-Config + 2 Ollama Local + 2 Google Cloud Node.
- Seguridad HBOS VAULT: Cifrado AES-256-GCM y clave soberana hbos-sec-...
- Trazabilidad: Persistencia inmutable en Qdrant Cloud (coleccion hbos_metricas).